

스프린트 미션 #13

1. 서론

프로젝트 배경 및 목표

이번 미션에서는 포르투갈 은행의 마케팅 데이터를 분석하여, 고객의 정기 예금 가입 여부를 예측할 수 있는 분류 모델을 개발하고자 한다.

또한, 모델을 통해 파악한 주요 예측 요인을 바탕으로 마케팅 전략을 제안함으로써, 은행의 마케팅 효율성을 향상시키는 것을 목표로 한다.

분석은 다음과 같은 단계로 접근하였다.



1. 데이터 구조 파악 및 정제
2. 파생 변수 생성 / 로그 변환
3. 전처리 방식 비교
4. 샘플링 실험
5. 성능 비교 및 하이퍼파라미터 튜닝
6. 최종 모델 선정
7. 주요 변수 기반인사이트 도출

최종적으로 가장 적합한 수요 예측 모델을 선정하고자 한다.

2. 데이터 탐색 및 전처리

2.1 변수 유형 정리


분석에 사용한 데이터는 bank-additional-full.csv이며, 유럽 은행의 전화 마케팅 캠페인 이력을 바탕으로 고객의 예금 가입 여부를 예측하기 위한 데이터이다. 총 20개의 Feature와 1개의 Target 변수(y)가 존재하며, 범주형 변수와 수치형 변수가 혼합된 구조이다.

원본 데이터

변수명	타입	설명
age	수치형	나이
job	범주형	직업
marital	범주형	결혼 여부
education	범주형	교육 수준
default	범주형	신용 불량 여부
housing	범주형	주택 대출 여부
loan	범주형	개인 대출 여부
contact	범주형	연락 수단
month	범주형	마지막 연락 월
day_of_week	범주형	마지막 연락 요일
duration	수치형	마지막 통화 시간 (초)
campaign	수치형	해당 캠페인 중 연락 횟수
pdays	수치형	이전 캠페인 후 경과일수
previous	수치형	이전 캠페인 연락 횟수
poutcome	범주형	이전 캠페인 결과
emp.var.rate	수치형	고용 변화율
cons.price.idx	수치형	소비자 물가지수
cons.conf.idx	수치형	소비자 신뢰지수
euribor3m	수치형	3개월 유리로 금리
nr.employed	수치형	고용자 수
y	이진형	예금 가입 여부 (yes/no)

2.2 결측치 및 0값 확인


기술적으로는 결측치(None 또는 NaN)는 존재하지 않지만, 일부 변수(`default` , `housing` , `loan` , `education` , `pdays` , `poutcome`)에서는 'unknown' 이 결측치를 대체하고 있음이 확인되었다. 해당 값의 분포를 확인한 결과, 특정 변수에서는 'unknown' 의 비율이 과도하게 높거나 희소하여 별도의 처리 또는 제거 여부를 검토할 필요가 있다.




```
python 결국치 처리 >>> <class 'pandas.core.frame.DataFrame'> RangeIndex: 41188 entries, 0
to 41187 Data columns (total 21 columns): # Column Non-Null Count Dtype ---
-----
0 age 41188 non-null int64 1 job 41188 non-null object 2 marital 41188 non-
null object 3 education 41188 non-null object 4 default 41188 non-null object 5 housing
41188 non-null object 6 loan 41188 non-null object 7 contact 41188 non-null object 8 mont
h 41188 non-null object 9 day_of_week 41188 non-null object 10 duration 41188 non-null in
t64 11 campaign 41188 non-null int64 12 pdays 41188 non-null int64 13 previous 41188 non-
null int64 14 poutcome 41188 non-null object 15 emp.var.rate 41188 non-null float64 16 co
ns.price.idx 41188 non-null float64 17 cons.conf.idx 41188 non-null float64 18 euribor3m
41188 non-null float64 19 nr.employed 41188 non-null float64 20 y 41188 non-null object d
types: float64(5), int64(5), object(11)
```

2.3 수치형 변수 분포

- **age** : 대체로 30~40대에 집중되어 있으며, 70세 이상 고령층도 일부 존재한다. 특이한 이상치는 확인되지 않았다.
- **duration** : 0~500초 구간에 집중되어 있으며, 1000초 이상은 극소수이다. 오른쪽으로 길게 늘어진 분포를 보인다.
- **campaign** : 대부분 1~3회이며, 10회 이상은 드물다. 50회 이상의 값은 극단치로 간주된다.
- **pdays** : 999가 전체의 대부분을 차지하며, 나머지 값은 0~300 사이에 분포한다. 뚜렷한 비대칭 분포가 확인된다.
- **previous** : 값의 대부분이 0이고, 나머지는 1~2회 정도에 집중된다. 극단적인 값은 거의 없다.
- **emp.var.rate** : 소수의 이산적 값들로 구성되어 있으며, 특정 값에 데이터가 몰려 있다.
- **cons.price.idx** , **cons.conf.idx** : 몇몇 수치에 빈도가 몰려 있는 형태이며, 연속 변수라기보다는 이산적 지표에 가까운 특성을 가진다.
- **euribor3m** : 5%에 가까운 값에 빈도가 집중되어 있으며, 1~5% 구간에 분포되어 있다.
- **nr.employed** : 5000명대에서 밀집 분포되어 있으며, 일부 값에서 뾰족한 분포를 보인다.





AI 기능을 사용하려면 입력 후 스페이스 키를 누르세요. 명령어 사용 시에는 '/'를 누르세요...

2.3.1 이상치

수치형 변수의 이상치를 IQR 기준으로 탐지한 결과, 전체 데이터(41,188건) 중 약 26.29%에 해당하는 10,828건의 행에서 이상치가 포함되어 있는 것으로 나타났다. 특히 `previous`, `duration`, `campaign`, `pdays` 등 캠페인 관련 변수에서 이상치가 빈번하게 확인되었다.

변수명	이상치 수	전체 대비 비율
<code>previous</code>	5,625	13.66%
<code>duration</code>	2,963	7.19%
<code>campaign</code>	2,406	5.84%
<code>pdays</code>	1,515	3.67%
<code>age</code>	469	1.14%
<code>cons.conf.idx</code>	447	1.09%
<code>emp.var.rate</code>	0	0.00%
<code>cons.price.idx</code>	0	0.00%
<code>euribor3m</code>	0	0.00%
<code>nr.employed</code>	0	0.00%



- `previous`

해당 변수는 이진적 해석이 가능한 특성을 보이며, 값이 0인 경우가 대부분이었고, 1 이상일 때 전환율이 유의하게 상승하였다. 따라서 값을 단순화하여 `had_previous_contact` 라는 이진 파생 변수로 대체하고, 이상치 여부에 상관없이 원본 컬럼은 제거하였다.

- `duration`

마지막 통화 시간 변수는 전환율과 매우 밀접한 관계를 가지지만, 실제 예측 시점에서는 사전에 알 수 없는 정보이므로 변수 자체의 활용 가능성이 낮다고 판단하였다. 마지막 모델링 과정에서 해당 변수를 추가한 채로 돌린 결과 / 제거한 채로 돌린 결과로 나누어 분석하였다.

- `campaign`

고객과의 반복 연락 횟수는 10회 이상일 경우 전환율이 급격히 감소하는 경향이 있으며, 30회 이상은 이상치로 판단하였다. 따라서 해당 변수는 최대 15로 상한값을 적용하고, 초과값은 모두 클리핑 처리하였다.

그 외 변수들(`age`, `pdays`, `cons.conf.idx`)에 대해서는 극단값의 영향력이 상대적으로 적거나, 파생 변수화 또는 로그 변환 등을 통해 분포의 왜곡을 완화할 수 있다고 판단하여 별도 제거 없이 유지하였다.

2.3.2 변수 간 상관관계 분석

수치형 변수 간의 Pearson 상관계수를 시각화한 결과, 다음과 같은 관계가 확인되었다.

- `euribor3m`, `emp.var.rate`, `nr.employed`


이 세 변수는 서로 **0.90 이상 수준의 매우 강한 양의 상관관계**를 보였다. 이는 경기 상황을 나타내는 지표들이 비슷한 흐름을 가진다는 의미로 해석된다. 나중에 로그 변환으로 전처리를 진행하였다.

- `pdays`와 `previous`

두 변수는 **-0.59 수준의 강한 음의 상관관계**를 나타냈다. 과거 캠페인에서 연락받은 이력이 있는 고객일수록 이전에 더 자주 연락을 받았다고 해석하였다.

- 그 외 변수들


`age`, `duration`, `campaign` 등의 변수는 다른 수치형 변수들과의 상관관계가 낮았다. `duration`은 타 변수와 거의 상관이 없으나 전환율에는 직접적 영향을 주었다.




2.4 범주형 변수 분포



범주형 변수별로 **y**와의 관계를 시각화하고 주요 패턴을 확인하였다.

- **job:** **admin.** 과 **blue-collar** 직군이 가장 큰 비중을 차지하였고, **technician**, **services**, **management** 순으로 빈도수가 높았다. **student**, **retired**, **unemployed** 는 상대적으로 적은 수이나, 이후 분석에서 전환율이 높은 그룹으로 나타났다.
- **marital:** **married** 가 전체의 절반 이상을 차지하며, **single** 과 **divorced** 가 그 뒤를 이었다. **unknown** 값은 극소수였다.
- **education:** **university.degree**, **high.school**, **basic.9y** 가 주요 분포를 형성하였으며, **professional.course**, **basic.6y**, **basic.4y** 등이 뒤를 이었다. **illiterate** 와 **unknown** 은 극소수에 해당한다.
- **default:** 대부분의 고객이 **no** 로 응답하였으며, **yes** 는 매우 희소하였다. 약 8000건 이상의 **unknown** 값이 존재하여 추후 unknown, no로 이진화 정리를 할 예정이다.
- **housing:** **yes** 와 **no** 가 비슷한 수준으로 분포하고 있으며, **unknown** 은 소수이다.
- **loan:** **no** 응답이 압도적으로 많고, **yes** 는 상대적으로 적은 편이다. **unknown** 값은 소수 존재한다.
- **contact:** **cellular** 을 통한 연락이 대부분을 차지하며, **telephone** 은 절반 이하 수준이다.
- **month:** **may** 의 빈도가 월등히 높았으며, **jul**, **aug**, **jun**, **nov** 등의 순으로 분포하였다. **mar**, **oct**, **sep**, **dec** 는 상대적으로 빈도수가 매우 낮은 편이다. 캠페인 시기 불균형이 존재함을 의미한다.
- **day_of_week:** 요일별로 고른 분포를 보였으며, 각 요일 간 큰 차이는 없었다. 이는 마케팅 활동이 요일에 관계없이 고르게 이루어졌음을 시사한다.



- **poutcome:** 대부분의 고객이 **nonexistent** 로 응답하였으며, **failure** 와 **success** 는 각각 소수에 해당하였다. 특히 **success** 는 매우 적은 수이지만 전환율은 가장 높게 나타나므로, 중요한 변수로 판단된다.
- **y:** Target 변수인 **y** 는 **no** 가 전체의 약 88% 이상을 차지하고 있으며, **yes** 는 약 12%에 불과하여 클래스 불균형이 존재함을 확인하였다. 모델 학습 시에는 언더샘플링-오버샘플링을 고려할 예정이다.





🔥 ▼ 최종 전처리 요약, 정리

- **age**
 - 30~40대에 집중되어 있고, 고령층(≥ 60) 전환율이 높음
 - **log_age** (로그 변환) 생성 및 **age_group** (5단계 구간 파생 변수) 생성
- **job**
 - **management**, **blue-collar**, **technician** 등 주요 직군 외 희소 범주 존재
 - 2% 미만 범주 '**rare**' 로 통합, 이후 one-hot 인코딩
- **marital**
 - **married** 비중 높고, **single** 에서 전환율 상대적으로 높음
 - 범주 유지 후 one-hot 인코딩
- **education**
 - **secondary** 중심, **illiterate**, **unknown**, **basic.x** 계열 희소
 - 희소 범주 '**rare**' 로 통합 후 one-hot 인코딩
- **default**
 - 대부분 **no**, **unknown** 과 **yes** 매우 희소
 - **no** 는 0, 그 외는 1로 변환한 이진 변수로 처리
- **housing**, **loan**
 - **unknown** 포함한 3분류 구성
 - 범주 유지 후 one-hot 인코딩
- **contact**
 - **cellular** 중심, **telephone** 은 낮은 전환율
 - 범주 유지 후 one-hot 인코딩
- **month**
 - **may** 에 데이터 집중, **mar**, **dec** 전환율 높음
 - 월 순서 유지하며 one-hot 인코딩
- **day_of_week**
 - 요일별 차이 크지 않음, **thu** 전환율 약간 높음
 - 범주 유지 후 one-hot 인코딩
- **duration**
 - 전환율과 강한 상관관계 있으나 예측 시 사용 불가
 - 모델 학습에는 사용하지 않음
- **campaign**
 - 과도한 값일수록 전환율 낮음, 3 이하에서 높음
 - 상한값 15로 제한, **interaction_term** 생성 시 사용
- **pdays**
 - 대부분 999 (미연락), 999 외는 전환율 높음
 - **was_contacted_before** (연락 여부) 파생 변수 생성 후 원본 제거
- **previous**
 - 0이 대다수, 1 이상일 때 전환율 높음
 - **had_previous_contact** 파생 변수 생성 후 원본 제거
- **poutcome**
 - **nonexistent** 중심, **success** 전환율 매우 높음
 - 범주 유지 후 one-hot 인코딩
- **emp.var.rate**
 - 이산형 분포, 다른 변수들과 상관 높음
 - **log_emp_var_rate** 로 로그 변환 후 원본 제거

- `cons.price.idx`, `cons.conf.idx`, `euribor3m`, `nr.employed`
 - 스케일 크고 상관 높음, log 변환 적합
 - 각각 `log_변수명` 생성 후 원본 제거
- 상호작용 및 추가 파생 변수
 - `interaction_term`: `campaign * was_contacted_before`
 - `contact_ratio`: `previous / (campaign + previous)` 로 누적 접촉 비율

모델링 과정에서 `duration` 변수는 높은 예측력을 가지지만, 현실적인 예측 시나리오에서는 사용이 불가능한 변수로 보인다(캐글이나 대회 등에서는 사용 가능).

해당 변수는 콜센터 상담 시 고객과의 통화가 종료된 이후에만 확보되는 값으로, 실제 캠페인 실행 전에 활용할 수 없다. 즉, 예측 시점에 존재하지 않는 정보를 포함시킬 경우 데이터 누수가 발생하며, 이는 모델의 성능을 인위적으로 부풀리는 원인이 된다.

따라서 보고서용 최종 모델에서는 `duration` 을 제거한 상태로 성능을 비교하고, 이를 기준으로 전략을 수립하였다.

한편, `pdays`, `previous`, `default` 등의 변수는 다음과 같은 이유로 제거하거나 재구성하였다. `pdays` 와 `previous` 는 과거 캠페인과의 접점 여부를 의미하나, 그 자체로는 불연속적인 정보이며, 캠페인 이력의 유무만으로 파생 변수(`was_contacted_before`, `had_previous_contact`, `contact_ratio`)로 재구성하는 것이 더 유의미한 패턴을 반영한다고 판단했다.

2.5 최종 Feature Engineering 결과

최종적으로 학습에 사용된 feature는 다음과 같다.

변수명	시각화에서 확인된 특성 및 분포 요약	◀ 전처리 및 파생 변수 처리 요약
age	30~40대 비중이 가장 높고, 60세 이상 고령층에서 전환율이 높게 나타남	log_age 로그변환 생성, age_group 구간화 파생 변수 생성
job	관리직과 블루칼라 직군 중심 분포. 회소 직업 다수 존재함	등장 비율 2% 미만 회소 직업군은 'rare' 로 통합
marital	married가 가장 많고, single은 그보다 전환율 높게 나타남	one-hot 인코딩 후 모델 입력
education	secondary가 가장 흔하며, illiterate, basic.x 계열 등 회소값 다수 존재	rare/unknown 등은 'rare' 로 통합
default	대부분 no, unknown 존재. yes는 매우 드물어 해석이 어려움	no =0, 그 외(yes, unknown)=1로 이진 인코딩
housing	대출 보유자(yes)가 많으며, 보유자 비중이 높을수록 전환율 낮음	one-hot 인코딩
loan	대다수 no, 일부 yes, unknown 존재. 전환율은 유사함	one-hot 인코딩
contact	cellular 방식 비중 매우 높고, telephone는 낮음	one-hot 인코딩
month	may가 가장 많으나 전환율은 매우 낮음. mar, dec, oct 등은 전환율이 높음	one-hot 인코딩
day_of_week	요일별 분포 큰 차이 없음. thu에 약간의 전환율 상승 효과	one-hot 인코딩
duration	전환율과 강한 상관관계를 가지며, 평균 이상에서는 가입률 급상승	모델 입력에서는 제외 예정 (테스트 이후 최종 결정)
campaign	대부분 1~3회에 집중, 과도한 횟수는 전환율 낮음	최대 15로 상한 적용 (min(x, 15)), interaction_term 1
pdays	대부분 999 (이전 연락 없음 의미), 일부만 0~300 사이	was_contacted_before 이진 파생 변수로 변환 후 제거
previous	대부분 0회, 1회 이상일 경우 전환율 상승	had_previous_contact 이진 파생 변수로 변환 후 제거
poutcome	nonexistent 압도적 다수. success 일 경우 전환율 매우 높음	one-hot 인코딩
emp.var.rate	이산적 값이며, 상관관계 높은 변수들과 함께 움직임. 음수값 존재	최소값 보정 후 log_emp_var_rate 생성 → 원본 제거
cons.price.idx	값들이 특정 구간에 몰려 있음. log scale에서 변화 적절함	log_cons_price_idx 생성 → 원본 제거
cons.conf.idx	일부 값에서 치우침 존재. 값의 크기 변화폭은 크지 않음	log_cons_conf_idx 생성 → 원본 제거
euribor3m	5%대에 집중된 경향. 전환율과도 밀접한 관련 있음	log_euribor3m 생성 → 원본 제거
nr.employed	emp.var.rate, euribor3m과 높은 상관관계 보임	log_nr_employed 생성 → 원본 제거
interaction_term	캠페인 수 × 이전 연락 여부 → 전환율과 상호작용 존재 확인	파생 변수 생성 및 유지
contact_ratio	previous / (campaign + previous) → 연락의 '속속도' 비율 해석 가능	0으로 나눔 방식을 포함하여 파생 변수 생성
y	전체 중 약 11.7%가 yes, 나머지는 no	yes =1, no =0 으로 인코딩

3. 모델링

본 단계에서는 앞선 EDA 과정을 통해 도출한 결과를 바탕으로, 고객의 정기 예금 가입 여부(y)를 예측하는 분류 모델을 개발하고, 이를 통해 마케팅 전략에 실질적인 시사점을 도출하는 것이다.

많은 모델을 돌려봤고, 상당히 많은 시행착오가 있었다. 때문에 최종 선정 모델과 이전의 시행착오 모델을 두 섹션으로 나누어 작성하였다.

▼ 3.1 모델링 시행착오

초기 모델링 단계에서는 기본적인 전처리 및 피처 엔지니어링을 적용한 후, 다양한 알고리즘을 폭넓게 테스트 하였다.

- `duration`, `default` 변수의 포함 여부에 따른 성능 비교
- `age` 는 구간화 처리, `campaign` 은 이상치 클리핑(최대 15)
- `job`, `education` 등의 희소 범주는 병합 처리
- 클래스 불균형 보안을 위해 SMOTE를 적용한 모델과 비교 실험
- 모델 종류: AdaBoost, Gradient Boosting, XGBoost, LightGBM, Naive Bayes 등 총 7종

모 델	Accuracy	Precision	Recall	F1 Score	ROC AUC
0	Naive Bayes	0.872663	0.434311	0.431034	0.432666
1	XGBoost	0.899369	0.610738	0.294181	0.397091
2	LightGBM	0.901432	0.650259	0.270474	0.382040
3	Random Forest	0.890872	0.527725	0.297414	0.380427
4	Gradient Boosting	0.902282	0.686930	0.243534	0.359586
5	Logistic Regression	0.897062	0.619760	0.223060	0.328051
6	Decision Tree	0.843651	0.317814	0.338362	0.327766
7	AdaBoost	0.901675	0.725191	0.204741	0.319328

해당 실험에서는 Accuracy는 전반적으로 높게 나타났으나, Recall이 낮아 전반적인 모델 성능의 균형이 부족하다는 판단이 들었다. 이에 따라 전처리 전략을 수정하였다.

수정된 전략에서는 연속형 변수에 대해 로그 변환을 도입하고, `balance`, `emp.var.rate`, `cons.price.idx` 등은 shift 후 log 변환하여 정규성을 확보하였다. 추가적으로 다음과 같은 파생 변수를 생성하였다:

- `was_contacted_before`, `had_previous_contact` : 이진 파생 변수
- `contact_ratio = previous / (campaign + previous)`
- `interaction_term = campaign * was_contacted_before`
- `log_*` 계열 변수들 (예: `log_euribor3m`, `log_cons_price_idx`, `log_age` 등)

Sampling 전략에 따라 예측 성능이 크게 달라짐을 확인하였고, 다음과 같은 세 가지 방식을 비교하였다.

Accuracy	Precision	Recall	F1 Score	ROC AUC
SMOTE	0.900704	0.620438	0.305316	0.409244
UnderSampling	0.822125	0.350741	0.680316	0.462854
No Sampling	0.901918	0.666052	0.259339	0.373320

이러한 실험 결과를 바탕으로, LightGBM 모델을 기준으로 세 가지 Sampling 전략을 모두 적용한 후 ROC AUC, Precision, Recall, F1 Score를 비교하였다. 그 결과, 실전 운영 관점에서는 UnderSampling 모델이 가장 균형 잡힌 성능을 보이는 것으로 판단되었다.

추가 실험으로는 `default` 변수의 처리 방식 변화가 있다. 해당 변수는 초기에 `'yes'` 응답이 극소수여서 제거하였으나, 이후 `'unknown'` 값을 `'yes'` 로 간주하여 1로 인코딩한 결과, F1 Score가 소폭 상승하였다. 이로써 `default` 변수는 최종 모델에도 포함하게 되었다.

마지막으로, `duration` 변수의 활용 여부에 따른 성능 차이를 비교하기 위해, `duration` 을 포함한 별도의 전처리 버전을 구성하였다. 이후 동일한 모델을 적용한 결과, ROC AUC가 0.95 이상으로 크게 상승하며 `duration` 의 높은 예측력을 재확인할 수 있었다.


3.2 최종 모델 구성 및 비교

최종적으로는 목적에 따라 다음 두 가지 모델을 비교하고, 각 모델의 적용 범위에 따라 선택적으로 활용할 수 있도록 정리하였다.

모델 A: duration 제외 모델

- Sampling 전략: UnderSampling
- Classifier: LightGBM
- Threshold: 0.5
- 주요 특징: 미래 정보를 배제한 현실적인 예측 모델
- 실제 마케팅 실무 적용에 적합

지표	값
Accuracy	87.5%
Precision	45.8%
Recall	59.3%
F1 Score	51.7%
ROC AUC	0.808



모델 B: duration 포함 모델

- Sampling 전략: No Sampling
- Classifier: LightGBM

- Threshold: 0.5
- 주요 특징: `duration` 을 활용하여 최대 성능 달성, 캠페인 사후 분석 혹은 실험적 분석에 적합

지표	값
Accuracy	91.9%
Precision	67.1%
Recall	55.6%
F1 Score	60.9%
ROC AUC	0.950

두 모델의 선택은 용도에 따라 결정된다.

모델 A는 실제 예측이 필요한 마케팅 운영에 사용하기 적합하며,

모델 B는 캠페인 종료 후의 효과 분석 및 내부 성능 평가용으로 활용하는 것이 바람직하다.

4. 주요 변수 해석 및 전략 제안

4.1 모델 A (duration 제외): UnderSampling, LightGBM 기준

LightGBM 모델을 기반으로 `duration` 을 제외한 상태에서 모델을 학습한 결과, 가장 높은 예측력을 가진 변수로는 `log_age` , `log_euribor3m` , `campaign` , `contact_ratio` , `log_cons_price_idx` 등이 도출되었다.

EDA 결과, 그리고 해당 모델 자료를 이용하여 다음과 같은 전략을 제안한다.

